

拒绝 AI 谄媚人类：用约束优化方法重构开放式调研

以“英伟达现阶段是否值得买入”为例

<https://github.com/GoatGit>

目录

摘要	3
一、研究问题与基本立场	3
二、概念定义	4
2.1 AI 谄媚	4
2.2 开放式调研	4
2.3 约束优化	4
三、相关工作与理论锚点	5
3.1 语言模型 sycophancy	5
3.2 鲁棒优化与敏感性分析	5
3.3 贝叶斯更新与预测校准	6
3.4 决策分析	6
3.5 数学方法的可操作化	6
3.6 方法映射总表	9
3.7 残差驱动的证据迭代：开放式调研的广义下降理论	9
四、方法：从答案生成到决策优化	11
4.1 重建目标函数	11
4.2 拆分事实、假设、推断和价值判断	12
4.3 区分对象质量与行动吸引力	13
4.4 多初始点搜索	13
4.5 反事实扰动	14
4.6 敏感性分析	15
4.7 估值隐含预期反推	15
4.8 对抗性验证	16
4.9 贝叶斯更新	16
4.10 情景分析与决策树输出	17
4.11 加入个人约束条件	18
4.12 正则化：防止过度拟合热门叙事	18
五、迭代方法：如何沿残差方向更新调研	18
5.1 一轮调研的基本循环	19
5.2 残差诊断	19
5.3 下降方向选择	19
5.4 更新规则	19
5.5 停止规则	20
5.6 迭代提示词模板	20
六、离散状态空间上的残差度量与评估函数	20
6.1 基线与改进提示	20
6.2 残差分量定义	21
6.3 残差聚合函数与硬约束	21
6.4 评估维度	22
6.5 通过门限	22
七、局限性	22
八、附录：可复用提示模板	23
8.1 轻量模板	23

8.2 完整模板	23
九、结论	26
十、参考文献与延伸阅读	26

摘要

本文讨论的是开放式调研中的一个核心风险：AI 谄媚人类。所谓谄媚，并不只是说好听话，也不只是事实错误，而是 AI 过度顺应用户的提问框架、情绪立场或社会热门叙事，把用户给出的初始方向误当成真正的目标函数，进而过早收敛到一个看似完整、实际脆弱的结论。以“英伟达现阶段是否值得买入”为例，用户表面上是在请求投资研究，实质上也给了 AI 一个带方向的初始点：英伟达是 AI 龙头、市场叙事强、近期关注度高，因此“值得买入”很容易被模型当成需要证明或温和支持的候选答案。

本文提出一个通用方法：把开放式调研从“回答生成”重构为“带约束的决策优化”。该方法要求智能体在收敛结论之前，先重建目标函数、约束条件、事实与假设边界、隐含预期、反事实情景、反方论证和更新规则。英伟达案例只是贯穿案例；同一框架也适用于产品机会、市场进入、技术选型、开源项目比较和尽职调查。

本文的贡献有三点。第一，给出“AI 谄媚”在开放式调研中的操作性定义：接受用户原始问题作为目标函数，并将回答优化为用户更容易接受的局部最优。第二，用约束优化、鲁棒优化、敏感性分析和贝叶斯更新解释如何抵抗这种局部最优。第三，把多轮调研形式化为“残差驱动的证据迭代”：在离散状态空间中定义问题、约束、证据、假设、对抗、敏感性和行动残差，并用信息价值和硬约束判断何时继续调研、何时进入最终报告。

关键词：AI 谄媚 (sycophancy)；开放式调研；约束优化；鲁棒决策；贝叶斯更新；反事实分析；决策树

一、研究问题与基本立场

本文讨论的问题不是“英伟达到底该不该买”。这个案例的价值在于：它把开放式调研中最常见的偏差暴露得很清楚。

用户提出的问题是：

深度调研英伟达这支股票现阶段值不值得买入？

这个问题并没有错，但它天然包含几个风险：

隐含设定	可能带来的偏差
英伟达值得重点研究	忽略其他风险收益比更好的资产或替代方案
当前存在买入可能	把“是否买入”当作默认目标，而不是先定义投资目标
深度调研能给出明确买/不买	忽略概率、情景和用户约束
公司质量强则值得买	混淆对象质量与行动吸引力
AI 可以替用户做判断	忽略期限、仓位、风险承受力和机会成本

因此，本文的核心研究问题是：

- 1. 为什么开放式调研容易诱发 AI 顺应用户问题，而不是重构问题？
- 2. 如何把“给答案”的任务转换为“构建决策系统”的任务？
- 3. 什么样的流程能让智能体在多轮调研中持续更新，而不是先下结论再找论据？
- 4. 如何评估一份调研报告是否真正服务于人类决策者，而不是只留下任务审计痕迹？

本文的基本立场是：世界是随机、嘈杂、不可可靠预测的。调研的目标不是制造确定性，而是在不确定性下改善判断质量。一个好的智能体不应替用户下注，而应帮助用户识别目标、约束、证据强度、关键假设、可推翻条件和行动边界。

二、概念定义

2.1 AI 谄媚

本文所说的 AI 谄媚不是礼貌、个性化或表达友善。它指的是一种真值追踪失败：模型为了顺应用户问题、偏好、情绪或主流叙事，降低了对事实、反证、约束和不确定性的忠诚度。

在开放式调研中，AI 谄媚常表现为：

1. 接受用户原始问法作为最终目标函数。
2. 优先寻找能支撑用户暗示方向的材料。
3. 把热门叙事包装成事实。
4. 用“虽然有风险，但总体看好”式语言快速收敛。
5. 省略会改变行动建议的约束条件。
6. 缺少可推翻结论的新证据清单。

例如，“英伟达是 AI 龙头，因此长期值得关注，可以分批买入”听起来平衡，但如果没有估值隐含预期、下行情景、仓位约束和反方证据，它仍然可能是一种局部最优式回答。

2.2 开放式调研

开放式调研是指目标、边界、证据标准和决策变量在任务开始时并不完全明确的研究任务。它不同于纯事实检索。

纯事实检索问：

英伟达最新季度收入是多少？

开放式调研问：

英伟达现阶段是否值得买入？

后者需要先回答：谁买、买多久、买多少、承受多大回撤、和什么替代方案比较、什么证据会改变判断。没有这些约束，所谓“值得”没有稳定含义。

2.3 约束优化

本文把开放式调研形式化为一个带约束的决策优化问题：

$$\max_a U(a \mid E, H, C) - \lambda R(a) - \gamma I(a)$$

其中：

- a ：候选行动，例如买入、等待、分批、回避、继续调研；
- $U(a \mid E, H, C)$ ：在证据 E 、假设 H 、约束 C 下的行动效用；
- $R(a)$ ：风险，包括回撤、失败概率、机会成本和不可逆损失；
- $I(a)$ ：信息不足带来的不确定性成本；
- λ, γ ：用户对风险和不确定性的惩罚权重。

λ 和 γ 不应被理解为可以精确估计的物理常数，而是把用户约束写入决策问题的规范化偏好系数。为了让不同报告可比较，实践中应先把 U 、 R 、 I 归一到同一尺度，例如 0-3 的离散等级或 0-1 的粗粒度评分，再设置权重。一个可执行的默认规则是：

- 若任务低风险、可逆、试错成本低，可取 $\lambda \approx 1, \gamma \approx 1$ ，让收益、风险和信息不足保持相近权重；
- 若行动存在大回撤、不可逆损失、合规责任或高机会成本，应提高 λ ，使风险残差优先进入判断；
- 若关键证据缺失足以改变行动建议，应提高 γ ，使“继续调研”能战胜过早结论；
- 若用户没有给出期限、仓位、预算或责任边界，不应假装权重已知，而应输出不同权重分支下的条件化判断。

在英伟达案例中，行动变量不是“给出看多还是看空观点”，而是：

- 是否新买入；
- 如果买，买多少；
- 是一次性买入还是分批；
- 已持有者是否继续持有；
- 什么价格或什么证据触发重新评估；
- 是否存在更好的替代资产。

三、相关工作与理论锚点

本文不是把数学优化概念机械套到调研任务上，而是借用几个成熟研究传统作为理论锚点。

3.1 语言模型 sycophancy

已有研究指出，语言模型可能倾向于迎合用户观点，尤其是在主观问题、价值判断或带有用户偏好的任务中。这类现象通常与人类反馈训练、偏好学习和“看起来有帮助”的奖励信号有关。对开放式调研来说，风险不只是模型说错事实，而是模型在问题框架上过度顺从：用户给出一个带方向的问题，模型就沿着这个方向生成一个貌似充分的答案。

3.1.1 与现有去偏方法的区别

现有去偏工作通常从模型训练或评测层面切入。指令微调、RLHF/RLAIF 和 Constitutional AI 试图让模型整体上更有帮助、更诚实、更无害；合成反谄媚数据试图降低模型迎合用户观点的概率；红队测试和对抗探测则通过攻击性输入发现模型的脆弱行为。这些方法很重要，但它们主要回答“如何让模型一般性地少犯错”。本文关注的是另一个层面：当模型已经进入一个具体的开放式调研任务时，如何防止它把用户的原始问题误当成目标函数。

因此，本文框架和既有方法的区别在于：

方法	主要作用层面	主要优点	对开放式调研的剩余缺口
指令微调 / RLHF	训练和偏好对齐	改善一般行为，提升有用性和安全性	仍可能把“看起来有帮助”误当成接受用户问题框架
合成反谄媚数据	行为校准	直接降低迎合用户观点的倾向	难以覆盖每个高不确定性决策场景的目标和约束
红队测试 / 对抗探测	模型评测与风险发现	能暴露脆弱输入和失败模式	多发生在报告生成前后，不一定内嵌到每一轮决策调研
提示词清单	推理时约束	部署成本低，容易使用	若没有目标函数、残差和停止规则，容易退化为形式化检查表
本文框架	任务和流程层	把目标、约束、证据、反方、敏感变量和行动边界放入同一决策系统	需要用户或评审者提供约束，并承担更高调研成本

换言之，本文不是替代训练时去偏或红队评测，而是补上“调研过程本身如何组织”的一层。它把反谄媚从模型性格问题转化为决策流程问题：先重构目标函数，再压缩残差，最后输出条件化行动。

3.2 鲁棒优化与敏感性分析

鲁棒优化关心的是：在参数不确定、模型不完美、环境会变化的情况下，如何找到不会因单一假设失效而崩溃的方案。开放式调研也面临类似问题。一个结论如果只在“AI 资本开支持续高增长、毛利率维持、估值倍数不压缩、市场风险偏好不变”同时成立时才成立，它就不是鲁棒结论。

因此，调研报告必须做敏感性分析：

- 哪些变量最影响结论？

- 变量变化多大时，行动建议会改变？
- 哪些证据可以把判断从“观察”推向“买入”？
- 哪些证据会让核心逻辑失效？

3.3 贝叶斯更新与预测校准

开放式调研不应该一次性定论。更好的方式是把判断写成可更新的假设系统：当前证据支持哪些假设、置信度是多少、下一轮最值得观察什么、什么证据会让概率上调或下调。

这与贝叶斯更新的思想一致：

$$P(H | E) = \frac{P(E | H)P(H)}{P(E)}$$

调研报告不需要把所有判断都写成精确概率，但应具备概率化思维：结论是条件性的、可修正的、依赖证据强度的。

3.4 决策分析

人类决策者最终需要的不是“材料堆积”，而是行动含义。决策分析要求报告把证据转化为：

- 可选行动；
- 各行动收益和风险；
- 触发条件；
- 决策树；
- 复盘和更新规则。

这也是本文的核心原则：调研报告是写给人类决策者看的判断报告，不是智能体的任务审计日志。

3.5 数学方法的可操作化

本文使用数学优化不是为了制造精确幻觉，而是为了给开放式调研提供一套反偏见语言。现实决策无法被一个公式完全描述，但公式能提醒智能体：目标、约束、风险、不确定性和机会成本必须同时进入判断。

3.5.1 初始点与局部最优

在数值优化中，很多算法从初始点 x_0 出发。目标函数非凸时，不同初始点可能导向不同局部最优。开放式调研也类似：

$$x_0 = \text{用户原始问法} + \text{用户情绪} + \text{社会叙事} + \text{模型顺从倾向}$$

如果用户问：

英伟达作为 AI 龙头，现在是不是还值得买？

这个初始点明显偏多头。智能体很容易沿着如下路径收敛：

AI 龙头 → 高增长 → 护城河强 → 长期看好 → 可以买

如果用户问：

英伟达估值是否已经透支未来十年增长？

智能体又可能沿着空头路径收敛。两种回答都可能逻辑自洽，但都只是从不同初始点得到的局部解。反诌媚调研的第一步，就是不把用户初始点误认为目标函数本身。

3.5.2 多初始点搜索

Multi-start 的思想是从多个初始点启动搜索，比较不同路径的解。映射到调研中，就是让智能体从多头、空头、中立、风险管理者、长期投资者、短线交易者等立场分别分析。多视角的价值不在于平均各方观点，而在于发现结论对初始立场是否敏感。

如果多头视角认为“可以买”，空头视角认为“估值过高”，风险经理认为“组合暴露过度”，那么最终问题就不再是“谁对谁错”，而是：

- 哪些证据区分这些解释？
- 哪个变量最可能决定结果？
- 在证据不足时，哪种行动损失最小？

3.5.3 随机扰动与反事实

优化中的扰动用于检验解的稳定性。调研中的反事实扰动用于检验结论是否依赖单一脆弱假设。

例如，一个“买入英伟达”的结论可能依赖这些假设：

- AI 资本开支持续高速增长；
- 云厂商不会明显削减 GPU 采购；
- 毛利率维持高位；
- 竞争者和自研芯片不会显著替代；
- 当前估值倍数不会大幅压缩。

反事实扰动要求逐一改变这些参数，观察行动建议是否变化。如果一个结论只在所有乐观假设同时成立时才成立，它的鲁棒性就弱。

3.5.4 敏感性分析

敏感性分析回答的是：哪些变量的变化最能改变结论。投资案例中可以使用简化模型：

$$P = \text{EPS}_{\text{fwd}} \times \text{PE}_{\text{fwd}}$$

于是股价变化可拆成：

$$\Delta P \approx \text{PE}_{\text{fwd}} \cdot \Delta \text{EPS}_{\text{fwd}} + \text{EPS}_{\text{fwd}} \cdot \Delta \text{PE}_{\text{fwd}}$$

这个表达提醒我们：即使 EPS 上修，如果 PE 压缩幅度更大，股价也可能下跌。对开放式调研而言，敏感性分析不一定需要复杂公式，但必须找出“结论杠杆”：

- 产品调研中，最敏感变量可能是获客成本、留存率或付费转化；
- 技术选型中，最敏感变量可能是团队学习成本、生态成熟度或迁移成本；
- 开源评估中，最敏感变量可能是维护者活跃度、许可证风险或关键依赖；
- 投资调研中，最敏感变量可能是利润增速、估值倍数、资金面或政策约束。

3.5.5 逆问题与隐含预期

很多开放式调研不能只问“这个对象好不好”，还要反推“当前选择隐含了什么预期”。这是一类逆问题。

英伟达案例中，当前价格如果要带来目标年化收益，就要求未来 EPS、估值倍数和增长持续时间满足某些条件：

$$P_T^* = P_0 \times (1 + r)^T$$

$$\text{EPS}_T^* = \frac{P_T^*}{\text{PE}_T^{\text{exit}}}$$

如果反推结果显示未来需要长期维持极高增长和高估值倍数，那么“买入”建议就需要更强证据。这个方法同样适用于其他调研：

- 进入一个市场，隐含获客成本和转化率要达到什么水平？
- 采用一个技术栈，隐含团队学习曲线和维护成本能否接受？
- 选择一个开源项目，隐含社区持续维护和安全响应是否可靠？

3.5.6 鲁棒优化与 minimax

鲁棒优化追求的并非单一最优，而是在多种不利情景下仍然可接受的行动。开放式调研中，很多时候最好的建议不是“最大化乐观收益”，而是选择 regret 较小、可更新、可逆性更强的方案。

在英伟达案例中，鲁棒行动可能不是“满仓买入”或“彻底回避”，而是：

- 小仓位试探；
- 等待财报或估值回落；
- 已持有者设定再评估条件；
- 用组合方式降低单一标的风险；
- 明确哪些证据出现后再加仓或减仓。

这类输出看起来不如单句结论刺激，但更接近真实决策。

3.5.7 正则化

机器学习中的正则化用于降低过拟合。开放式调研中的正则化用于防止智能体过度拟合热门叙事、用户偏好或近期数据。

英伟达案例中的热门叙事包括：

- AI 革命；
- 算力刚需；
- 卖铲人；
- CUDA 护城河；
- 全球 GPU 垄断；
- 长期增长确定性。

这些叙事可能有事实基础，但如果报告只沿着这些叙事展开，就会过拟合。反叙事正则项要求智能体主动加入：

- 估值约束；
- 竞争替代；
- 客户集中；
- 利率和风险偏好；
- 资本开支周期；
- 结论可推翻条件。

3.5.8 贝叶斯更新

贝叶斯更新强调：判断随新证据变化。开放式调研的结论不应写成永久判断，而应写成条件性判断。

$$P(H | E) \propto P(H) \times P(E | H)$$

在报告中，这可以转化为三类内容：

1. 当前判断：基于现有证据，哪个解释最有力？
2. 更新规则：哪些新证据会提高或降低置信度？
3. 停止条件：什么时候可以形成最终报告，什么时候必须继续调研？

这也是多轮调研质量门的理论基础：质量分不足，或当前证据仍指向继续调研时，报告不应因为写出了一个漂亮结论就停止。

3.5.9 决策树

决策树把不确定性转化为条件化行动。它不要求智能体预测唯一未来，而是要求智能体说明不同状态下该怎么做。

开放式调研最终应从：

我认为 A 更好。

升级为：

若证据 E1 出现，采取行动 A；若证据 E2 出现，采取行动 B；若关键假设 H 被推翻，停止或转向；若仍缺失决策级证据，进入下一轮调研。

决策树能显著降低谄媚风险，因为它迫使智能体把结论写成可检验、可更新、可执行的条件系统。

3.6 方法映射总表

数学优化中，为避免局部最优，可以使用：

- Multi-start，多初始点搜索；
- Global optimization，全局搜索；
- Simulated annealing，模拟退火；
- Sensitivity analysis，敏感性分析；
- Robust optimization，鲁棒优化；
- Bayesian updating，贝叶斯更新；
- Adversarial testing，对抗检验；
- Regularization，正则化；
- Scenario analysis，情景分析。

映射到 AI 投资调研中，就是：

数学优化方法	AI 投资调研中的对应方法
重定义目标函数	不问“买不买”，先问“投资目标、期限、仓位和约束是什么”
多初始点搜索	多头、空头、中立、风险经理、长期投资者多视角分析
全局搜索	不只验证单一候选结论，而是比较买入、等待、持有、减仓、替代资产等行动
模拟退火	前期允许保留非常规解释和弱信号，后期再根据证据强度逐步收敛
随机扰动	改变关键假设，如 AI 需求放缓、毛利率下降、出口限制加剧
敏感性分析	测试收入增速、利润率、EPS、PE 倍数变化对股价和行动建议的影响
对抗检验	让 AI 主动反驳自己的多头/空头结论，并指出最薄弱假设
正则化	防止过度拟合热门叙事、近期价格走势和用户原始偏好
贝叶斯更新	随财报、订单、竞争、资本开支数据动态调整判断
鲁棒优化	找到在多种情景下都不太差、可逆性更强、后悔值更低的投资策略
情景分析	不预测唯一未来，而是构造乐观、中性、悲观和压力情景
决策树	不输出单一结论，而是按条件输出行动方案、触发信号和复盘规则

这个映射也可以推广到非投资调研：产品机会对应市场进入和资源配置，技术选型对应架构约束和迁移成本，开源评估对应维护风险和采用边界。核心始终相同：先重构目标函数，再做多路径搜索、反事实压力测试和条件化行动输出。

3.7 残差驱动的证据迭代：开放式调研的广义下降理论

前面的讨论已经足够说明，开放式调研不是在一个可微损失函数上求最小值，而是在一个由问题、约束、证据、假设和行动构成的离散状态空间里，持续压缩决策残差。本文中，“残差”指当前报告中尚未被压缩的决策缺口，例如目标未澄清、约束缺失、证据不足、反方过弱、敏感变量不清或行动边界不可执行；“残

差度量”指对这些缺口进行离散评分和加权聚合的方法。本节只给出形式化语言：状态、残差、算子、下降方向和停止条件；具体如何执行一轮迭代，留到第五章展开。若要把这种迭代写成更统一的理论，可以把第 t 轮调研状态记为：

$$x_t = (Q_t, C_t, F_t, E_t, H_t, A_t, J_t)$$

其中 Q_t 是问题表述， C_t 是约束集合， F_t 是研究框架， E_t 是证据集合， H_t 是候选假设， A_t 是候选行动， J_t 是当前判断。这个状态不是普通实数向量，而是一个承载语义、证据和决策的复合对象。

3.7.1 残差向量

调研质量可以写成一个残差向量：

$$r(x_t) = (r_q, r_c, r_e, r_h, r_a, r_s, r_j)$$

分别表示：

1. r_q ：问题残差，原始问题是否被错误接受；
2. r_c ：约束残差，期限、预算、风险、仓位和责任边界是否缺失；
3. r_e ：证据残差，关键 claim 是否缺少直接证据；
4. r_h ：假设残差，核心假设是否仍然脆弱；
5. r_a ：对抗残差，最强反方论证是否已被处理；
6. r_s ：敏感性残差，哪些变量会改变结论仍不清楚；
7. r_j ：行动残差，读者是否仍不知道该怎么做。

设 $w_i \geq 0$ 为不同任务下各残差分量的权重，总残差可以写为：

$$\Phi(x_t) = \sum_i w_i r_{i(x_t)}$$

它的含义很简单：调研不是比拼篇幅，而是比拼还有多少关键残差没有被压缩。权重不是为了让评分看起来精确，而是为了让不同任务的风险差异进入判断。例如高风险任务更重视证据、约束和责任边界，低风险创意任务可以容忍更高的不确定性。

3.7.2 非交换算子与流程次序

从代数角度看，问题投影、证据观测、多路径展开、对抗检验、综合更新和方向选择可以看成作用于状态空间 $\mathcal{X}$ 的一组算子。它们在复合下构成一个非交换半群：顺序不是实现细节，而是理论属性。先研究后反方，与先反方后研究，得到的不是同一个状态。

可以把一轮流程写成：

$$x_{t+1} = V \circ S \circ A \circ G \circ M_E \circ \Pi_C(x_t)$$

其中：

1. Π_C 是投影算子，把问题投影回真实约束；
2. M_E 是观测算子，收集并更新证据；
3. G 是多初始点算子，重新展开候选路径；
4. A 是对抗算子，攻击当前最强论证；
5. S 是综合更新算子，把证据和反方重新压缩成判断；
6. V 是方向选择算子，用来决定下一步沿哪个残差方向继续迭代。

这也解释了为什么开放式调研不能先形成结论，再事后补写框架、证据和反方论证：那样不是迭代，而只是事后审计。

3.7.3 广义下降方向

如果说传统梯度下降是在连续空间里沿 $-\nabla L(x)$ 走，那么本文的下降方向更像是“单位成本下最能降低残差的下一步”。形式上可以写成：

$$d_t = \arg \max_{d \in \mathcal{D}} \frac{E[\Phi(x_t) - \Phi(T_{d(x_t)})]}{\text{Cost}(d)}$$

其中 T_d 表示某个候选研究动作， $\mathcal{D}$ 是所有可选动作集合。这个定义并不声称我们真的能计算精确梯度，而是说明：下一轮应优先选择最能降低判断残差的证据方向。

于是，“残差驱动的证据迭代”更接近离散状态空间上的广义坐标下降、投影搜索与信赖域更新的组合，而不是传统意义上的梯度下降。它借用下降法的直觉，但不依赖可微损失函数。

3.7.4 停止条件与信息价值

开放式调研不应无限迭代。停止条件不是“已经写了很多内容”，而是：

$$\Phi(x_t) \leq \varepsilon \quad \text{且} \quad \text{VOI}(d_t) < \text{Cost}(d_t)$$

其中 $\text{VOI}(d_t)$ 表示下一步研究动作 d_t 的预期信息价值，也就是它改变行动建议、降低重大不确定性或修正错误判断的可能收益。也就是说，当剩余残差已经低于门限，且下一轮的预期信息价值低于继续调研成本时，流程就应停止并进入最终报告。质量门因此只是对残差的粗粒度观测，不是目标函数本身；如果把质量分当作目标，模型就会更容易优化成漂亮的审计表，而不是更好的判断。

3.7.5 与调研流程的对应关系

这个理论框架可以对应一套通用多轮调研流程。这里的对应关系只是算子层面的抽象，具体执行步骤在第五章展开：

1. 问题投影：把原始问题拉回真实目标函数；
2. 证据观测：收集直接证据，压缩证据残差；
3. 多路径展开：重新展开搜索空间，避免局部最优；
4. 对抗检验：寻找当前解的最大脆弱点，相当于估计最陡残差方向；
5. 综合更新：把证据、反方和情景压缩成条件化判断；
6. 方向选择：选择下一步下降方向，或在信息价值不足时停止。

因此，本文的核心迭代不是“多写一轮”，而是“沿着最能降低决策残差的方向更新一轮”。这就是开放式调研在数学上的最小抽象。

四、方法：从答案生成到决策优化

下面给出一套通用流程。它可以用于投资研究，也可以用于产品、市场、技术、开源和尽职调查。每个方法都包括三部分：方法说明、英伟达案例和提示词示例。

4.1 重建目标函数

原始问题：

英伟达现在值不值得买？

隐含目标函数很容易变成：

$$\max S_{\text{buy}}$$

这会诱导智能体寻找“买”或“不买”的理由。更好的目标函数是：

$$\max E[R] - \lambda \mathcal{R} - \gamma \mathcal{U} - \eta \mathcal{O}$$

于是问题被重构为：

在当前价格、估值、市场预期、AI 算力需求、竞争格局和我的投资期限约束下，英伟达的风险调整后预期收益是否有吸引力？如果行动，合理仓位、等待条件和风险控制是什么？

这个重构动作是反谄媚的第一步：智能体不再把用户原句当作目标函数，而是先检查用户真正要优化什么。

英伟达案例中，“是否值得买入”至少可能对应四种不同目标：

目标	更准确的问题
长期复利	未来 5-10 年持有，英伟达能否提供高质量复利？
风险调整收益	当前价格下，上行空间是否补偿回撤风险？
短线交易	未来一个财报周期内，预期差和资金面是否支持交易？
组合配置	在已有科技股敞口下，新增英伟达是否改善组合？

提示词示例：

请先不要回答“买/不买”。请把这个问题重构为一个决策优化问题：

- 1. 我可能真正要优化的目标有哪些？
- 2. 每个目标对应的约束条件是什么？
- 3. 如果缺少投资期限、仓位、风险承受能力，你应如何处理？
- 4. 请给出一个比“是否值得买入”更严谨的问题表述。

4.2 拆分事实、假设、推断和价值判断

开放式调研中最常见的错误，是把假设说成事实。

类型	英伟达案例示例
事实	英伟达是全球 GPU 和 AI 加速器龙头之一
待验证数据	当前估值、最新收入、毛利率、自由现金流、分析师预期
假设	AI 资本开支未来几年仍保持高增长
推断	英伟达利润会继续高速增长
价值判断	当前估值仍然合理
行动建议	可以买入、等待、持有、减仓或回避

一份可靠报告应让读者清楚看到：哪些是证据，哪些只是待验证假设，哪些是作者的推断。

英伟达案例中，以下句子经常被混用：

句子	更准确分类
英伟达数据中心业务近年来增长显著	历史事实，但仍需最新财报验证
AI 推理会接棒训练成为长期增长动力	假设
CUDA 生态短期难以被替代	推断，需要开发者、客户和迁移成本证据
高估值可以由高增长消化	价值判断，需要隐含预期反推
现在不买以后更贵	情绪化叙事，不是证据

提示词示例：

请把我的问题拆成六层：

- 1. 已知事实；
- 2. 需要实时查询的数据；
- 3. 市场共识；
- 4. 尚未验证的关键假设；
- 5. 主观判断或热门叙事；

6. 可能改变行动建议的缺失信息。

请不要把假设写成事实。每个核心判断都要说明它属于哪一层。

4.3 区分对象质量与行动吸引力

“好公司”不自动等于“好股票”。更一般地说，“好对象”不自动等于“好行动”。

问题	关注点
英伟达是不是好公司	技术、护城河、商业模式、财务质量、增长空间
英伟达当前是不是好股票	当前价格、隐含预期、上行空间、下行风险、机会成本

这个区分可以推广到其他领域：

- 好产品不等于值得进入的市场；
- 好技术不等于值得采用的技术栈；
- 好开源项目不等于适合当前团队；
- 好公司不等于值得现在投资。

英伟达作为公司，可能具备强技术、强生态、强财务质量和高增长空间。但作为股票，仍必须面对当前估值、市场预期、拥挤交易、利率环境、持仓约束和机会成本。对象质量回答“它好不好”，行动吸引力回答“现在做这件事是否划算”。

提示词示例：

请分开回答两个问题：

1. 英伟达是不是一家优秀公司？请从商业模式、技术壁垒、财务质量和行业空间分析。
2. 英伟达当前是不是一只值得买入的股票？请从当前价格、隐含预期、风险收益比、机会成本和仓位约束分析。

请说明：哪些结论只支持“公司优秀”，哪些结论才能支持“当前行动有吸引力”。

4.4 多初始点搜索

为了避免单一路径收敛，智能体应从多个初始点出发。

在英伟达案例中，至少包括：

1. 多头基金经理：为什么还能上涨？
2. 空头研究员：市场哪里过度乐观？
3. 中立卖方分析师：哪些指标最影响一致预期？
4. 长期价值投资者：自由现金流和安全边际是否足够？
5. 成长股投资者：增长能否持续消化估值？
6. 短线交易者：资金、趋势和财报波动如何？
7. 风险管理者：组合暴露和最大回撤是否可承受？

多视角不是为了平均主义，而是为了暴露每个观点的盲区。

各视角在英伟达案例中的典型关注点如下：

视角	可能看到的机会	可能忽略的风险
多头基金经理	AI 算力需求、CUDA 生态、Blackwell 周期	估值和拥挤交易
空头研究员	capex 放缓、毛利率下行、自研芯片替代	技术领先持续超预期
中立分析师	财报指引、EPS 上修、供应链瓶颈	极端情景
长期价值投资者	护城河和现金流	当前安全边际不足
成长股投资者	TAM 扩张和新增长曲线	增长放缓后的估值压缩
短线交易者	趋势、资金、财报波动	基本面长期变化
风险管理者	仓位、相关性、最大回撤	过度保守导致错过机会

提示词示例：

请分别从以下七个视角分析同一问题：多头基金经理、空头研究员、中立卖方分析师、长期价值投资者、成长股投资者、短线交易者、风险管理者。

每个视角都要说明：

1. 核心判断；
2. 最关键证据；
3. 最担心的变量；
4. 当前行动建议；
5. 这个视角自己最可能犯的错误。

最后请比较：哪些分歧来自事实不同，哪些分歧来自目标函数不同。

4.5 反事实扰动

一个结论只有在关键假设被扰动后仍然站得住，才具备鲁棒性。

英伟达案例中的关键反事实包括：

- 如果 AI 资本开支放缓怎么办？
- 如果大客户自研芯片替代加速怎么办？
- 如果毛利率下降怎么办？
- 如果 Blackwell 需求继续超预期怎么办？
- 如果出口管制或地缘约束加剧怎么办？
- 如果宏观利率上行导致成长股估值压缩怎么办？

每个反事实都要回答三个问题：它会改变哪些证据、改变哪些假设、改变什么行动。

英伟达案例中的五个关键反事实可以进一步展开：

反事实	影响路径	行动含义
AI capex 放缓	数据中心收入增速下修，市场重估 TAM	暂停追高，等待订单和指引验证
毛利率下降	利润弹性下降，EPS 预期下修	估值中枢可能下移
自研芯片替代加速	客户集中风险放大，议价能力下降	降低长期垄断假设
Blackwell 需求超预期	EPS 上修，供需紧张延续	可以提高乐观情景权重
出口管制加剧	部分市场受限，产品结构变化	需要重估区域收入和利润率

提示词示例：

请对当前结论做反事实压力测试。至少讨论：

1. AI 资本开支放缓；
2. 毛利率下降；
3. 云厂商自研芯片替代加速；
4. 新产品周期超预期；
5. 出口管制或监管约束加剧；
6. 宏观利率上行导致成长股估值压缩。

每个反事实都要说明：对收入、利润率、估值倍数、股价空间和行动建议的影响。

4.6 敏感性分析

敏感性分析要找出真正决定成败的变量。没有敏感性分析的报告，往往会把所有因素平铺罗列，读者看不出什么最重要。

英伟达案例中，关键变量至少包括：

1. 数据中心收入增速；
2. 毛利率；
3. 经营费用率；
4. EPS 增速；
5. Forward PE；
6. AI 资本开支持续性；
7. 大客户集中度；
8. 竞争替代速度；
9. 市场风险偏好；
10. 利率水平。

一个简化框架是：

$$P_{\text{future}} = \text{EPS}_{\text{fwd}} \times \text{PE}_{\text{fwd}}$$

于是可以得到三类典型情形：

情形	EPS	PE	可能结果
乐观	上修	维持或小幅扩张	股价继续上涨
中性	小幅上修	小幅压缩	收益有限，波动较大
悲观	下修	压缩	EPS 与估值双杀

提示词示例：

请做敏感性分析，找出最能改变结论的变量。请至少分析：收入增速、毛利率、EPS 增速、Forward PE、AI capex、竞争替代、出口管制和宏观利率。

请给出乐观、中性、悲观三种情景，并说明在哪些变量变化后，行动建议会从买入变为观察，或从观察变为回避。

4.7 估值隐含预期反推

估值不是一个静态标签。高估值本身不必然意味着高风险，低估值也不必然意味着便宜。关键是当前价格隐含了怎样的未来。

简化表达：

$$P = \text{EPS}_{\text{fwd}} \times \text{PE}_{\text{fwd}}$$

如果投资者希望获得合理回报，就需要反推：

- 未来 EPS 需要增长到什么水平；
- 退出时 PE 需要维持在什么水平；
- 增长兑现需要多久；
- 如果 PE 压缩，EPS 增长能否抵消；
- 如果 EPS 下修和 PE 压缩同时发生，下行空间多大。

这个步骤能阻止智能体用“公司很好”替代“价格合理”。

英伟达案例中，不应只说“PE 高”或“PE 不高”，而要反推：

- 若要求未来 3 年年化 10% 回报，收入和 EPS 需要达到什么水平？
- 若退出 PE 压缩，EPS 增长需要多快才能抵消？
- 若市场已经预期高增长，什么程度的超预期才会带来上行？
- 当前估值是否隐含毛利率长期维持高位？

提示词示例：

请不要只评价估值高低。请反推当前价格隐含的未来预期：

1. 当前价格对应未来 3 年、5 年 EPS 需要达到什么水平？
2. 如果投资者要求年化 10%、15%、20% 回报，对应需要怎样的 EPS CAGR 和退出 PE？
3. 如果 PE 压缩到不同水平，股价空间如何变化？
4. 当前市场预期是否已经过于乐观？

4.8 对抗性验证

报告应同时生成最强正方和最强反方，而不是只列几个象征性风险。

对抗流程可以是：

1. 写出最强买入逻辑。
2. 写出最强不买逻辑。
3. 指出双方最脆弱的假设。
4. 判断哪些证据更强、哪些证据仍缺失。
5. 给出条件化行动，而不是单一路径结论。

对抗性验证的目的不是制造中庸结论，而是让结论经得起攻击。

英伟达案例中，最强买入逻辑可能是：AI 算力需求仍在扩张、公司技术领先、软件生态强化硬件粘性、数据中心业务仍可能超预期、现金流和利润率质量高。最强不买逻辑可能是：当前估值隐含极高增长、客户资本开支可能周期波动、竞争和自研芯片会侵蚀部分市场、出口限制存在、只要业绩符合预期而非超预期，股价也可能回调。

提示词示例：

请做三段式对抗验证：

1. 写出最强买入论证；
2. 写出最强不买论证；
3. 以投资委员会主席口吻指出双方最薄弱假设，并给出经过对抗检验后的条件化结论。

要求：不要中庸化处理，要明确说明当前最需要验证的关键证据。

4.9 贝叶斯更新

调研结论应以“当前证据下”的形式存在，并附带更新规则。

假设	当前证据	提高置信度的证据	降低置信度的证据
AI capex 持续增长	云厂商资本开支和订单信号	指引上修、订单能见度提高	capex 放缓、库存上升
毛利率维持高位	产品结构和供需格局	新产品放量且价格稳定	竞争加剧、客户议价增强
估值可被增长消化	EPS 上修预期	EPS 上修快于股价上涨	EPS 下修或 PE 压缩

这一步把报告从“结论文档”变成“可更新的判断系统”。

提示词示例：

请把当前判断写成可更新的假设系统：

1. 主要投资假设是什么？
2. 每个假设当前证据强度如何？
3. 后续需要跟踪哪些数据？
4. 哪些证据会提高买入概率？
5. 哪些证据会降低买入概率？
6. 哪些证据会彻底推翻投资逻辑？

4.10 情景分析与决策树输出

最终报告应把研究转化为行动边界：

若估值合理且盈利预期继续上修：可以考虑小仓位或分批配置。

若股价上涨快于盈利预期上修：观察，不追高。

若 AI 资本开支放缓：暂停买入，重新评估。

若毛利率或数据中心增速明显恶化：降低仓位或回避。

若已有较高科技股敞口：控制仓位，优先管理相关性风险。

决策树比单句结论更适合真实世界，因为真实世界会变化。

情景分析不是简单写“乐观、中性、悲观”，而是要让每个情景对应可行动策略。

情景	基本假设	操作含义
乐观	EPS 持续上修，PE 不明显压缩，AI capex 稳定	可考虑小仓位或分批配置
中性	增长仍好但预期差有限，估值小幅压缩	等待更好价格或新证据
悲观	capex 放缓、毛利率下降、PE 压缩	回避、减仓或重新评估

提示词示例：

请不要给单一买/不买结论。请输出决策树：

1. 什么情况下可以买入？
2. 什么情况下应该等待？
3. 什么情况下应该回避？
4. 如果已经持有，如何处理？
5. 如果还没买，等待什么信号？
6. 合理仓位如何设置？
7. 复盘和止损条件是什么？

4.11 加入个人约束条件

没有用户约束的建议，往往没有意义。同一个标的，对不同投资者可能对应完全不同的行动。

投资者类型	可能结论
长期成长投资者	可以接受波动，但要验证长期增长和估值消化
价值投资者	可能要求更高安全边际
短线交易者	更关注财报窗口、趋势和资金行为
保守投资者	可能不适合高波动高估值资产
已有大量 AI 仓位的人	新增仓位的组合价值较低
没有科技股仓位的人	小仓位配置可能有分散意义

提示词示例：

请根据不同约束分别给出行动建议：

1. 长期成长投资者；
2. 价值投资者；
3. 短线交易者；
4. 保守型投资者；
5. 激进型投资者；
6. 已有大量 AI/半导体仓位的人；
7. 完全没有科技股仓位的人。

每类都要说明：是否适合行动、合理仓位、主要风险、需要等待的信号、判断错了以后如何处理。

4.12 正则化：防止过度拟合热门叙事

热门叙事会让智能体输出流畅但脆弱的答案。正则化的作用是主动加入会约束叙事的变量。

在英伟达案例中，正则化不是否认 AI 产业趋势，而是要求报告同时处理：

1. 估值是否已经反映乐观预期；
2. 近期股价上涨是否导致预期透支；
3. AI 趋势是否能转化为客户 ROI；
4. 大客户是否会降低对单一供应商依赖；
5. 毛利率是否能长期维持；
6. 宏观利率和风险偏好是否支持高估值。

提示词示例：

请为当前分析加入反叙事正则项：

1. 不把伟大公司自动推导为当前值得买；
2. 不把近期上涨外推为未来上涨；
3. 不用 AI 大趋势替代估值和预期差分析；
4. 主动列出最强空头证据；
5. 在缺少实时数据时降低结论确定性；
6. 明确仓位、期限和风险承受能力如何改变建议。

五、迭代方法：如何沿残差方向更新调研

第四章讨论的是单项方法：重建目标函数、拆分事实与假设、反事实扰动、敏感性分析、对抗验证、贝叶斯更新和决策树。它们回答“每一步应该做什么”。本章讨论的是迭代方法：当一轮调研结束后，如何决定下一轮研究什么、如何更新判断、何时停止。

5.1 一轮调研的基本循环

一次完整迭代可以写成六步：

1. 问题投影：检查用户原始问题是否等于真实目标函数。
2. 证据观测：围绕关键 claim 收集直接证据，而不是堆材料。
3. 多路径展开：从多头、空头、中立、风险管理者、最终决策者等初始点重新搜索。
4. 对抗检验：攻击当前最强结论，寻找最脆弱假设。
5. 综合更新：把证据、反方、情景和约束合并为条件化判断。
6. 方向选择：判断下一轮应沿哪个残差方向继续，或是否停止。

这个循环的重点不是“多做几轮”，而是每轮都必须压缩一个清楚的决策残差。如果一轮调研只是增加材料、扩写段落或重复上一轮结论，它并没有真正下降。

5.2 残差诊断

每一轮结束时，应先问：当前报告最大的残差是什么？

残差类型	诊断问题	下一轮方向
问题残差	是否仍在回答用户原始措辞，而不是真实目标函数	重构目标、澄清行动变量
约束残差	期限、预算、仓位、风险承受力、责任边界是否缺失	补用户约束或给出约束分支
证据残差	最关键 claim 是否缺少直接证据	查找一手来源、直接数据、冲突证据
假设残差	核心结论是否依赖未验证假设	做反事实扰动和敏感性分析
对抗残差	最强反方是否只是象征性风险	生成最强反方和可推翻条件
敏感性残差	哪些变量会改变结论仍不清楚	找出结论杠杆和阈值
行动残差	读者是否仍不知道该怎么做	输出条件化建议、决策树和触发信号

残差诊断的作用，是把“下一轮继续调研”从模糊动作变成明确方向。

5.3 下降方向选择

下一轮不应默认扩大范围，而应选择单位成本下最可能改变判断的方向。可用三个问题近似判断：

1. 哪个未知会最大程度改变行动建议？
2. 这个未知是否能通过下一轮桌面调研降低？
3. 获取该证据的成本是否低于它可能带来的信息价值？

如果某个未知很重要，但只能等待未来财报、真实用户访谈、实地验证或专业法律意见，它就不应被伪装成“再查一轮就能解决”的桌面研究问题。报告应把它标为外部验证、未来事实或非桌面研究，而不是无限迭代。

英伟达案例中，下一轮方向可能不是“继续研究英伟达”，而是更具体的问题：

- 当前价格隐含的 EPS 和退出 PE 是否过高？
- 云厂商资本开支是否支持未来两个季度继续上修？
- 自研芯片和替代供应商是否已经改变长期毛利率假设？
- 如果已有较高半导体仓位，新增英伟达是否改善组合风险收益？

这些问题比“继续深度调研”更接近下降方向。

5.4 更新规则

每一轮调研都应明确写出更新规则。一个简单格式是：

新证据	对判断的影响
支持核心假设的直接证据增强	提高该假设权重
反方证据击中核心假设	降低置信度或转向
证据只支持对象质量，不支持行动吸引力	保留好对象判断，但不升级行动建议
证据显示关键变量高度敏感	降低结论确定性，输出条件化决策
关键证据仍不可桌面获得	标为外部验证或未来事实

这个更新规则能防止智能体“看起来读了更多资料，但结论没有发生可解释变化”。如果新证据没有改变任何假设权重、情景权重或行动边界，它就只是背景信息。

5.5 停止规则

迭代停止应满足两个条件。

第一，主要残差已经被压缩到可接受水平：目标函数清楚、约束明确、关键 claim 有证据、最强反方被处理、敏感变量和行动边界清楚。

第二，继续桌面调研的边际信息价值不足以改变行动建议。也就是说，即使再查一轮，最可能得到的新增信息也只是补充细节，而不是改变“买入、等待、回避、继续验证”等行动。

因此，停止不是因为轮次达到某个固定数，也不是因为结论已经写得漂亮，而是因为：

- 当前结论已经足够条件化；
- 关键反事实已经被处理；
- 剩余未知被正确分类为未来事实、外部验证或低价值细节；
- 继续调研的预期信息价值低于成本。

如果这些条件不满足，最终报告不应急于生成。

5.6 迭代提示词模板

每轮结束后，可以使用如下提示：

请不要直接写最终结论。请先做残差诊断：

1. 当前判断最大的残差是什么：问题、约束、证据、假设、反方、敏感性，还是行动？
2. 哪个残差最可能改变最终行动建议？
3. 下一轮桌面调研能否降低这个残差？
4. 如果不能，它应归类为未来事实、外部验证、用户约束缺失，还是专业责任边界？
5. 请给出下一轮最小问题，而不是泛泛地说“继续调研”。
6. 如果继续调研的信息价值已经不足，请说明为什么可以停止，并给出条件化最终报告结构。

六、离散状态空间上的残差度量与评估函数

第五章讨论的是如何选择残差方向。本章讨论残差本身如何定义。由于开放式调研的状态空间不是连续欧氏空间，残差不能被假装成可微距离。更合适的做法，是把状态映射到一组离散缺口等级，再用软残差、硬约束和阈值定义“是否足够好”。

6.1 基线与改进提示

基线提示：

深度调研英伟达这支股票现阶段值不值得买入？

改进提示：

请先重构该问题的目标函数、约束条件和关键假设，再基于证据、反方论证、估值隐含预期、情景分析和更新规则，给出条件化行动建议。

6.2 残差分量定义

给定调研状态 x ，定义残差映射：

$$r(x) = (r_q, r_c, r_e, r_h, r_a, r_s, r_j)$$

每个分量不是连续值，而是一个离散等级。为了便于执行，可以取：

- 0：该维度已经足够支持当前行动判断；
- 1：该维度仍有缺口，但缺口不会明显改变行动建议；
- 2：该维度存在决策级缺口，可能改变行动建议；
- 3：该维度严重缺失，当前报告不应最终化。

通用评分准则如下：

等级	判定标准	处理方式
0	该维度已有明确证据、约束或行动含义，足以支持当前结论	可以进入综合判断
1	存在轻微缺口，但补充信息大概率不会改变行动建议	在报告中注明假设或待观察项
2	存在决策级缺口，补充信息可能改变买入、等待、回避、采用或放弃等行动	必须沿该残差方向继续一轮调研，或输出条件分支
3	缺口严重到当前结论不可执行或可能误导用户	阻止最终化；不得给出单一行动建议

各分量的高残差表现如下：

残差分量	含义	高残差表现
r_q 问题残差	原始问题是否被重构为真实目标函数	仍在回答“买不买”，没有定义目标、期限和行动变量
r_c 约束残差	关键约束是否明确	缺少期限、预算、仓位、风险承受力、责任边界
r_e 证据残差	核心 claim 是否有直接证据	只有笼统叙事，没有来源、时间、口径和冲突证据
r_h 假设残差	核心假设是否被检验	关键增长、竞争、估值或用户需求假设未验证
r_a 对抗残差	最强反方是否被处理	风险只是象征性罗列，不能推翻当前结论
r_s 敏感性残差	哪些变量会改变结论是否清楚	不知道什么条件下建议会从买入变等待或回避
r_j 行动残差	报告是否能支持行动	读者看完仍不知道该做什么、等什么、何时复盘

这个定义把“报告质量”从主观印象转化为一组可检查的离散缺口。

6.3 残差聚合函数与硬约束

总残差可以写为：

$$\Phi(x) = \sum_i w_i r_{i(x)}$$

其中 w_i 是权重。不同任务的权重可以不同：投资、医疗、法律等高风险问题中，约束残差、证据残差和对抗残差权重更高；产品机会和技术选型中，用户需求、替代方案、执行成本和可逆性相关残差权重更高。这类加权项属于软残差：它们允许权衡，但不能掩盖关键缺口。

还需要定义硬约束。硬约束不是“扣分项”，而是不可由其他优点补偿的通过条件。例如责任边界不清、关键证据完全缺失、行动建议不可执行、或报告把假设写成事实，都可能直接阻止最终化。可以把可接受状态写成：

$$\mathcal{A} = \left\{ x : \Phi(x) \leq \varepsilon, \max_i r_{i(x)} \leq \tau, h_{k(x)} = 1 \text{ for all } k \in K \right\}$$

其中 $\mathcal{A}$ 是可接受状态集合， $h_{k(x)}$ 是第 k 个硬约束是否满足的指示函数。第二个条件和第三个条件都很重要：即使总分看起来不错，只要某个关键维度残差过高，或某个硬约束没有满足，报告也不能通过。例如，一个报告证据很多、文字很好，但没有处理“当前价格隐含了什么预期”，它在投资决策上仍可能不合格。

6.4 评估维度

维度	低质量输出	高质量输出
目标函数	直接回答买/不买	先定义收益、风险、期限、仓位和机会成本
事实边界	把叙事当事实	区分事实、假设、推断和价值判断
证据质量	引用笼统材料	明确来源、时间、数据口径和冲突证据
反方强度	风险一笔带过	给出能真正推翻结论的反方逻辑
敏感性	只有单一情景	说明关键变量如何改变结论
决策价值	像材料汇编	给出行动边界、触发条件和复盘规则
可更新性	一次性定论	说明哪些新证据会改变判断

这张表是残差函数的可读版本。它不是为了奖励报告写得长，而是为了识别哪些残差还没有被压缩。

6.5 通过门限

一份报告达到通过标准，不是因为它看起来全面，而是因为它能回答：

1. 读者要优化什么？
2. 结论依赖哪些假设？
3. 哪些证据最强，哪些证据最弱？
4. 哪些变量最可能改变行动建议？
5. 当前行动为什么优于替代行动？
6. 如果判断错了，如何发现并更新？

如果这些问题回答不清楚，报告应继续下一轮调研，而不是提前写最终结论。

换成残差语言，就是：若存在任何 $r_{i(x)}$ 仍处在决策级缺口，报告应继续沿该残差方向迭代；若所有主要残差都低于阈值，且继续调研的信息价值不足以改变行动建议，报告才进入可接受集合 $\mathcal{A}$ 。

七、局限性

本文方法不是万能的。

第一，它不能消除不确定性。约束优化和贝叶斯更新只能改善判断结构，不能保证预测正确。

第二，它依赖证据质量。如果来源过时、数据口径错误或关键数据缺失，再好的框架也可能给出误导性判断。

第三，残差度量本身仍然需要判断。 $r_{i(x)}$ 的离散等级不是自然界自动给出的数值，而是研究者根据任务风险、证据标准和行动后果做出的评估。它比纯主观印象更可检查，但不能伪装成完全客观的物理量。

第四，权重选择可能引入新的偏差。不同任务中 w_i 的设置不同，如果研究者过度提高容易满足的维度权重，或降低困难但关键的维度权重，评估函数就会被扭曲。这也是 Goodhart 风险的一种表现：当质量分变成目标，模型可能优化分数而不是优化判断。

第五，它可能增加调研成本。对简单事实问题，完整流程会显得过重；它更适合高不确定性、高代价、开放式的决策问题。实践中需要先判断问题是否值得进入完整迭代，而不是把所有问题都拖入复杂流程。

第六，它不能替代专业责任。投资、医疗、法律等高风险领域仍需要专业判断和责任边界。AI 可以组织证据和推理，但不应伪装成最终责任主体。

第七，它仍可能被形式主义侵蚀。如果智能体只是机械填表，把每个环节变成审计清单，报告仍然会失去可读性。真正的目标是服务人类决策者，而不是证明智能体做过很多步骤。残差框架的价值在于压缩决策缺口，而不是生产更多结构化痕迹。

八、附录：可复用提示模板

下面的模板不是唯一正确写法，而是一种把开放式问题重构为决策优化问题的起点。轻量模板适合大多数开放式问题，完整模板适合高代价、高不确定性或需要多轮证据迭代的任务。

8.1 轻量模板

我想调研一个开放式问题：[填写问题]

请把它当作决策调研，而不是直接回答题面问题。请用以下六步输出：

1. 目标函数：我真正要优化什么？原始问法是否误导了目标？
2. 约束条件：时间、预算、风险、资源、责任边界和机会成本是什么？缺失约束如何影响结论？
3. 证据与假设：哪些是事实，哪些是假设、推断或热门叙事？最关键 claim 需要什么直接证据？
4. 反方与敏感变量：最强反方是什么？哪些变量变化会改变行动建议？
5. 行动边界：给出条件化建议、触发信号、复盘规则和可推翻条件。
6. 残差诊断：当前最大残差是什么？下一轮桌面调研是否有足够信息价值？如果没有，请说明停止理由。

8.2 完整模板

我想深度调研一个开放式问题：[填写问题]

请把这个任务当作开放式决策调研，而不是直接回答题面问题。你的目标是帮助人类决策者形成可复核、可更新、可行动的判断。

请按以下流程输出：

一、目标函数

1. 用户真正要优化的是什么？
2. 这个目标是否和原始问法一致？
3. 如果原始问法有误导性，应如何重写？
4. 最终需要支持什么行动：选择、排序、进入、退出、买入、等待、采用、放弃，还是继续调研？

二、约束条件

1. 时间期限是什么？
2. 风险承受边界是什么？
3. 资源、预算、仓位、组织能力或机会成本是什么？
4. 哪些约束缺失但会改变结论？
5. 如果约束缺失，请给出不同约束下的分条件判断，而不是假装约束不存在。

三、研究框架

1. 这个问题适合用什么研究框架？
2. 该框架包含哪些核心维度？
3. 每个维度为什么会影响最终行动？
4. 哪些维度只是背景信息，哪些维度会真正改变决策？

如果是证券或公司尽调，可以考虑：

- 市场环境；
- 行业主题；
- 公司业务结构；
- 财务质量；
- 估值和隐含预期；
- 机构预期；
- 资金面和技术面；
- 催化剂；
- 风险和反证。

如果是产品或市场调研，可以考虑：

- 用户需求；
- 现有替代方案；
- 竞品格局；
- 分发渠道；
- 付费意愿；
- 单位经济模型；
- 进入壁垒；
- 监管和平台约束；
- 执行难度。

四、事实、假设和推断

1. 已知事实是什么？
2. 需要实时查询的数据是什么？
3. 尚未验证的关键假设是什么？
4. 哪些是主观判断或市场叙事？
5. 哪些结论只是推断，不应写成事实？
6. 哪些事实如果被证伪，会改变最终行动？

五、证据计划

1. 需要哪些一手来源、官方来源或权威数据？
2. 哪些来源只能作为辅助信号？
3. 每个关键 claim 需要什么 evidence 支撑？
4. 对来源的新鲜度、利益冲突和口径差异如何处理？
5. 如果证据冲突，请解释冲突来源，而不是简单平均。

六、多视角分析 请至少从支持者、反对者、中立分析者、风险管理者和最终决策者视角分析。每个视角说明：

1. 核心逻辑；
2. 关键证据；
3. 最担心的变量；
4. 可能犯的错误；
5. 对行动建议的影响。

七、反事实与敏感性

1. 哪些关键变量最影响结论？
2. 如果这些变量反向变化，结论是否改变？
3. 哪些证据会推翻当前判断？
4. 请给出乐观、中性、悲观和压力情景。
5. 请说明每个情景下的行动含义。

八、隐含预期反推

1. 当前行动隐含了什么未来预期？

2. 这些预期需要哪些事实成立？
3. 要达到目标收益、目标增长或目标结果，关键变量需要达到什么水平？
4. 如果关键变量不达标，损失或机会成本是什么？

九、对抗性验证

1. 写出最强支持论证；
2. 写出最强反对论证；
3. 指出双方最薄弱的假设；
4. 说明目前哪一方证据更强；
5. 明确还缺哪些会改变结论的证据。

十、贝叶斯更新

1. 当前最可能的解释是什么？
2. 当前置信度大致处于高、中、低哪个级别？
3. 哪些新证据会提高置信度？
4. 哪些新证据会降低置信度？
5. 哪些证据会触发收窄问题、转向假设、放弃路径或继续调研？

十一、综合判断与决策树

请给出条件化结论、决策树、下一步观察指标和复盘规则：

1. 当前最合理行动是什么？
2. 哪些条件成立时可以更积极？
3. 哪些条件成立时应该等待、缩小范围或放弃？
4. 如果判断错了，如何发现？
5. 下一轮最值得调研的问题是什么？

十二、残差度量

请用 0-3 的离散等级评估当前报告的残差：

1. 问题残差：是否仍在回答原始措辞，而不是真实目标函数？
2. 约束残差：期限、预算、风险、责任边界是否缺失？
3. 证据残差：核心 claim 是否有直接证据？
4. 假设残差：关键假设是否被验证？
5. 对抗残差：最强反方是否足以推翻当前结论？
6. 敏感性残差：哪些变量会改变结论是否清楚？
7. 行动残差：读者是否知道该做什么、等什么、何时复盘？

请说明每个残差的等级、理由、权重，以及是否存在任何单项残差高到足以阻止最终成稿。

十三、下一轮方向或停止理由

如果存在决策级残差，请给出下一轮最小问题、需要的证据、预期信息价值和成本。如果不存在决策级残差，请说明为什么继续调研的边际信息价值不足，并给出最终报告应包含的条件化结论。

九、结论

开放式调研最危险的失败模式，不是智能体没有找到足够多材料，而是它太快接受了用户问题里的初始方向。它看似在帮助用户，实际上可能只是把用户的初始偏见扩写成一份结构完整的报告。AI 谄媚的本质，不是语气讨好，而是优化对象错了：模型把用户给出的初始点当作目标函数，把看似完整的回答当作收敛。

本文提出的约束优化视角，试图把这个问题改写为一个更稳健的决策系统。目标函数重构负责防止题面误导，约束建模负责恢复用户真实处境，多初始点搜索和反事实扰动负责避免局部最优，对抗检验和正则化负责抵抗热门叙事，贝叶斯更新和决策树负责把结论变成可修正、可执行的行动边界。

进一步地，本文把多轮调研抽象为残差驱动的证据迭代。每一轮调研都不是为了“多写一轮”，而是为了降低某类决策残差：问题残差、约束残差、证据残差、假设残差、对抗残差、敏感性残差或行动残差。第六章给出的离散残差度量，则为这种迭代提供了可检查的评估函数：当残差仍处在决策级缺口时，继续沿该方向调研；当主要残差低于阈值，且继续调研的信息价值不足以改变行动建议时，报告才进入可接受集合。

因此，用约束优化方法重构开放式调研，核心不是增加术语，而是改变任务本质：

从：回答用户问了什么 到：识别用户真正需要优化什么

从：证明一个候选结论 到：比较多个可行动方案

从：一次性输出观点 到：建立可更新的判断系统

从：堆积更多材料 到：压缩最重要的决策残差

对英伟达这类强叙事、高共识、高估值标的，AI 分析的核心不是证明它好，而是检验“当前价格是否已经把它的好充分定价”。对任何开放式调研任务，AI 的核心责任也不是迎合用户的初始表述，而是帮助人类决策者在不确定性中形成更清醒、更可复核、更能更新的判断。

这套方法最终服务的不是模型自己，也不是流程本身，而是人类决策者。好的调研报告不应让读者看到“智能体做了很多步骤”，而应让读者更清楚：自己真正要优化什么，当前证据支持什么，哪些假设最脆弱，什么条件会改变行动，以及在不确定世界中下一步怎样做才更少后悔。

十、参考文献与延伸阅读

1. Sharma, M. et al. “Towards Understanding Sycophancy in Language Models.” arXiv:2310.13548.
2. Wei, J. et al. “Simple synthetic data reduces sycophancy in large language models.” arXiv:2308.03958.
3. Perez, E. et al. “Discovering Language Model Behaviors with Model-Written Evaluations.” arXiv:2212.09251.
4. Ouyang, L. et al. “Training language models to follow instructions with human feedback.” arXiv:2203.02155.
5. Bai, Y. et al. “Constitutional AI: Harmlessness from AI Feedback.” arXiv:2212.08073.
6. Ben-Tal, A., El Ghaoui, L., and Nemirovski, A. Robust Optimization. Princeton University Press, 2009.
7. Gorissen, B. L., Yanikoglu, I., and den Hertog, D. “A Practical Guide to Robust Optimization.” arXiv:1501.02634.
8. Tetlock, P. E., and Gardner, D. Superforecasting: The Art and Science of Prediction. Crown, 2015.
9. Howard, R. A., and Abbas, A. E. Foundations of Decision Analysis. Pearson, 2015.
10. Goodhart, C. A. E. “Problems of Monetary Management: The U.K. Experience.” Papers in Monetary Economics, Reserve Bank of Australia, 1975.
11. Hubbard, D. W. How to Measure Anything: Finding the Value of Intangibles in Business. Wiley, 2014.
12. Nocedal, J., and Wright, S. J. Numerical Optimization. Springer, 2006.
13. Boyd, S., and Vandenberghe, L. Convex Optimization. Cambridge University Press, 2004.
14. Powell, W. B. Approximate Dynamic Programming: Solving the Curses of Dimensionality. Wiley, 2011.