

拒绝 AI 谄媚人类：用约束优化方法重构开放式调研

以“英伟达现阶段是否值得买入”为例

<https://github.com/GoatGit>

目录

摘要	2
一、研究问题与基本立场	2
二、概念定义	3
2.1 AI 谄媚	3
2.2 开放式调研	3
2.3 约束优化	3
三、相关工作与理论锚点	4
3.1 语言模型 sycophancy	4
3.2 鲁棒优化与敏感性分析	4
3.3 贝叶斯更新与预测校准	4
3.4 决策分析	4
3.5 数学方法的可操作化	4
3.6 方法映射总表	7
四、方法：从答案生成到决策优化	8
4.1 重建目标函数	8
4.2 拆分事实、假设、推断和价值判断	9
4.3 区分对象质量与行动吸引力	10
4.4 多初始点搜索	10
4.5 反事实扰动	11
4.6 敏感性分析	12
4.7 估值隐含预期反推	12
4.8 对抗性验证	13
4.9 贝叶斯更新	13
4.10 情景分析与决策树输出	14
4.11 加入个人约束条件	15
4.12 正则化：防止过度拟合热门叙事	15
五、最小评估框架	15
5.1 基线与改进提示	16
5.2 评估维度	16
5.3 通过门限	16
六、局限性	16
七、附录：可复用提示模板	17
八、结论	19
九、参考文献与延伸阅读	19

摘要

本文讨论的是开放式调研中的一个核心风险：AI 谄媚人类。所谓谄媚，并不只是说好听话，也不只是事实错误，而是 AI 过度顺应用户的提问框架、情绪立场或社会热门叙事，把用户给出的初始方向误当成真正的目标函数，进而过早收敛到一个看似完整、实际脆弱的结论。以“英伟达现阶段是否值得买入”为例，用户表面上是在请求投资研究，实质上也给了 AI 一个带方向的初始点：英伟达是 AI 龙头、市场叙事强、近期关注度高，因此“值得买入”很容易被模型当成需要证明或温和支持的候选答案。

本文提出一个通用方法：把开放式调研从“回答生成”重构为“带约束的决策优化”。该方法要求 agent 在收敛结论之前，先重建目标函数、约束条件、事实与假设边界、隐含预期、反事实情景、反方论证和更新规则。英伟达案例只是 running example；同一框架也适用于产品机会、市场进入、技术选型、开源项目比较和尽职调查。

本文的贡献有三点。第一，给出“AI 谄媚”在开放式调研中的操作性定义：接受用户原始问题作为目标函数，并将回答优化为用户更容易接受的局部最优。第二，用约束优化、鲁棒优化、敏感性分析和贝叶斯更新解释如何抵抗这种局部最优。第三，给出可复用的调研流程、质量评估方法和局限性说明，使该方法能够落地到多轮调研工作流程中。

关键词：AI sycophancy；开放式调研；约束优化；鲁棒决策；贝叶斯更新；反事实分析；决策树

一、研究问题与基本立场

本文讨论的问题不是“英伟达到底该不该买”。这个案例的价值在于：它把开放式调研中最常见的偏差暴露得很清楚。

用户提出的问题是：

深度调研英伟达这支股票现阶段值不值得买入？

这个问题并没有错，但它天然包含几个风险：

隐含设定	可能带来的偏差
英伟达值得重点研究	忽略其他风险收益比更好的资产或替代方案
当前存在买入可能	把“是否买入”当作默认目标，而不是先定义投资目标
深度调研能给出明确买/不买	忽略概率、情景和用户约束
公司质量强则值得买	混淆对象质量与行动吸引力
AI 可以替用户做判断	忽略期限、仓位、风险承受力和机会成本

因此，本文的核心研究问题是：

- 1. 为什么开放式调研容易诱发 AI 顺应用户问题，而不是重构问题？
- 2. 如何把“给答案”的任务转换为“构建决策系统”的任务？
- 3. 什么样的流程能让 agent 在多轮调研中持续更新，而不是先下结论再找论据？
- 4. 如何评估一份调研报告是否真正服务于人类决策者，而不是只留下任务审计痕迹？

本文的基本立场是：世界是随机、嘈杂、不可可靠预测的。调研的目标不是制造确定性，而是在不确定性下改善判断质量。一个好的 agent 不应替用户下注，而应帮助用户识别目标、约束、证据强度、关键假设、可推翻条件和行动边界。

二、概念定义

2.1 AI 谄媚

本文所说的 AI 谄媚不是礼貌、个性化或表达友善。它指的是一种 truth-tracking failure：模型为了顺应用户问题、偏好、情绪或主流叙事，降低了对事实、反证、约束和不确定性的忠诚度。

在开放式调研中，AI 谄媚常表现为：

1. 接受用户原始问法作为最终目标函数。
2. 优先寻找能支撑用户暗示方向的材料。
3. 把热门叙事包装成事实。
4. 用“虽然有风险，但总体看好”式语言快速收敛。
5. 省略会改变行动建议的约束条件。
6. 缺少可推翻结论的新证据清单。

例如，“英伟达是 AI 龙头，因此长期值得关注，可以分批买入”听起来平衡，但如果没有估值隐含预期、下行情景、仓位约束和反方证据，它仍然可能是一种局部最优式回答。

2.2 开放式调研

开放式调研是指目标、边界、证据标准和决策变量在任务开始时并不完全明确的研究任务。它不同于纯事实检索。

纯事实检索问：

英伟达最新季度收入是多少？

开放式调研问：

英伟达现阶段是否值得买入？

后者需要先回答：谁买、买多久、买多少、承受多大回撤、和什么替代方案比较、什么证据会改变判断。没有这些约束，所谓“值得”没有稳定含义。

2.3 约束优化

本文把开放式调研形式化为一个带约束的决策优化问题：

$$\max_a U(a \mid E, H, C) - \lambda R(a) - \gamma I(a)$$

其中：

- a ：候选行动，例如买入、等待、分批、回避、继续调研；
- $U(a \mid E, H, C)$ ：在证据 E 、假设 H 、约束 C 下的行动效用；
- $R(a)$ ：风险，包括回撤、失败概率、机会成本和不可逆损失；
- $I(a)$ ：信息不足带来的不确定性成本；
- λ, γ ：用户对风险和不确定性的惩罚权重。

在英伟达案例中，行动变量不是“给出看多还是看空观点”，而是：

- 是否新买入；
- 如果买，买多少；
- 是一次性买入还是分批；
- 已持有者是否继续持有；
- 什么价格或什么证据触发重新评估；
- 是否存在更好的替代资产。

三、相关工作与理论锚点

本文不是把数学优化概念机械套到调研任务上，而是借用几个成熟研究传统作为理论锚点。

3.1 语言模型 sycophancy

已有研究指出，语言模型可能倾向于迎合用户观点，尤其是在主观问题、价值判断或带有用户偏好的任务中。这类现象通常与人类反馈训练、偏好学习和“看起来有帮助”的奖励信号有关。对开放式调研来说，风险不只是模型说错事实，而是模型在问题框架上过度顺从：用户给出一个带方向的问题，模型就沿着这个方向生成一个貌似充分的答案。

3.2 鲁棒优化与敏感性分析

鲁棒优化关心的是：在参数不确定、模型不完美、环境会变化的情况下，如何找到不会因单一假设失效而崩溃的方案。开放式调研也面临类似问题。一个结论如果只在“AI 资本开支持续高增长、毛利率维持、估值倍数不压缩、市场风险偏好不变”同时成立时才成立，它就不是鲁棒结论。

因此，调研报告必须做敏感性分析：

- 哪些变量最影响结论？
- 变量变化多大时，行动建议会改变？
- 哪些证据可以把判断从“观察”推向“买入”？
- 哪些证据会让核心逻辑失效？

3.3 贝叶斯更新与预测校准

开放式调研不应该一次性定论。更好的方式是把判断写成可更新的假设系统：当前证据支持哪些假设、置信度是多少、下一轮最值得观察什么、什么证据会让概率上调或下调。

这与贝叶斯更新的思想一致：

$$P(H | E) = \frac{P(E | H)P(H)}{P(E)}$$

调研报告不需要把所有判断都写成精确概率，但应具备概率化思维：结论是条件性的、可修正的、依赖证据强度的。

3.4 决策分析

人类决策者最终需要的不是“材料堆积”，而是行动含义。决策分析要求报告把证据转化为：

- 可选行动；
- 各行动收益和风险；
- 触发条件；
- 决策树；
- 复盘和更新规则。

这也是本文的核心原则：调研报告是写给人类决策者看的判断报告，不是智能体的任务审计日志。

3.5 数学方法的可操作化

本文使用数学优化不是为了制造精确幻觉，而是为了给开放式调研提供一套反偏见语言。现实决策无法被一个公式完全描述，但公式能提醒 agent：目标、约束、风险、不确定性和机会成本必须同时进入判断。

3.5.1 初始点与局部最优

在数值优化中，很多算法从初始点 x_0 出发。目标函数非凸时，不同初始点可能导向不同局部最优。开放式调研也类似：

$$x_0 = \text{用户原始问法} + \text{用户情绪} + \text{社会叙事} + \text{模型顺从倾向}$$

如果用户问：

英伟达作为 AI 龙头，现在是不是还值得买？

这个初始点明显偏多头。agent 很容易沿着如下路径收敛：

AI 龙头 → 高增长 → 护城河强 → 长期看好 → 可以买

如果用户问：

英伟达估值是否已经透支未来十年增长？

agent 又可能沿着空头路径收敛。两种回答都可能逻辑自洽，但都只是从不同初始点得到的局部解。反诘调研的第一步，就是不把用户初始点误认为目标函数本身。

3.5.2 多初始点搜索

Multi-start 的思想是从多个初始点启动搜索，比较不同路径的解。映射到调研中，就是让 agent 从多头、空头、中立、风险管理者、长期投资者、短线交易者等立场分别分析。多视角的价值不在于平均各方观点，而在于发现结论对初始立场是否敏感。

如果多头视角认为“可以买”，空头视角认为“估值过高”，风险经理认为“组合暴露过度”，那么最终问题就不再是“谁对谁错”，而是：

- 哪些证据区分这些解释？
- 哪个变量最可能决定结果？
- 在证据不足时，哪种行动损失最小？

3.5.3 随机扰动与反事实

优化中的扰动用于检验解的稳定性。调研中的反事实扰动用于检验结论是否依赖单一脆弱假设。

例如，一个“买入英伟达”的结论可能依赖这些假设：

- AI 资本开支持续高速增长；
- 云厂商不会明显削减 GPU 采购；
- 毛利率维持高位；
- 竞争者和自研芯片不会显著替代；
- 当前估值倍数不会大幅压缩。

反事实扰动要求逐一改变这些参数，观察行动建议是否变化。如果一个结论只在所有乐观假设同时成立时才成立，它的鲁棒性就弱。

3.5.4 敏感性分析

敏感性分析回答的是：哪些变量的变化最能改变结论。投资案例中可以使用简化模型：

$$P = \text{EPS}_{\text{fwd}} \times \text{PE}_{\text{fwd}}$$

于是股价变化可拆成：

$$\Delta P \approx \text{PE}_{\text{fwd}} \cdot \Delta \text{EPS}_{\text{fwd}} + \text{EPS}_{\text{fwd}} \cdot \Delta \text{PE}_{\text{fwd}}$$

这个表达提醒我们：即使 EPS 上修，如果 PE 压缩幅度更大，股价也可能下跌。对开放式调研而言，敏感性分析不一定需要复杂公式，但必须找出“结论杠杆”：

- 产品调研中，最敏感变量可能是获客成本、留存率或付费转化；
- 技术选型中，最敏感变量可能是团队学习成本、生态成熟度或迁移成本；
- 开源评估中，最敏感变量可能是维护者活跃度、许可证风险或关键依赖；
- 投资调研中，最敏感变量可能是利润增速、估值倍数、资金面或政策约束。

3.5.5 逆问题与隐含预期

很多开放式调研不能只问“这个对象好不好”，还要反推“当前选择隐含了什么预期”。这是一类逆问题。

英伟达案例中，当前价格如果要带来目标年化收益，就要求未来 EPS、估值倍数和增长持续时间满足某些条件：

$$P_T^* = P_0 \times (1 + r)^T$$

$$\text{EPS}_T^* = \frac{P_T^*}{\text{PE}_T^{\text{exit}}}$$

如果反推结果显示未来需要长期维持极高增长和高估值倍数，那么“买入”建议就需要更强证据。这个方法同样适用于其他调研：

- 进入一个市场，隐含获客成本和转化率要达到什么水平？
- 采用一个技术栈，隐含团队学习曲线和维护成本能否接受？
- 选择一个开源项目，隐含社区持续维护和安全响应是否可靠？

3.5.6 鲁棒优化与 minimax

鲁棒优化追求的不是单一最优，而是在多种不利情景下仍然可接受的行动。开放式调研中，很多时候最好的建议不是“最大化乐观收益”，而是选择 regret 较小、可更新、可逆性更强的方案。

在英伟达案例中，鲁棒行动可能不是“满仓买入”或“彻底回避”，而是：

- 小仓位试探；
- 等待财报或估值回落；
- 已持有者设定再评估条件；
- 用组合方式降低单一标的风险；
- 明确哪些证据出现后再加仓或减仓。

这类输出看起来不如单句结论刺激，但更接近真实决策。

3.5.7 正则化

机器学习中的正则化用于降低过拟合。开放式调研中的正则化用于防止 agent 过度拟合热门叙事、用户偏好或近期数据。

英伟达案例中的热门叙事包括：

- AI 革命；
- 算力刚需；
- 卖铲人；
- CUDA 护城河；
- 全球 GPU 垄断；
- 长期增长确定性。

这些叙事可能有事实基础，但如果报告只沿着这些叙事展开，就会过拟合。反叙事正则项要求 agent 主动加入：

- 估值约束；
- 竞争替代；
- 客户集中；
- 利率和风险偏好；
- 资本开支周期；
- 结论可推翻条件。

3.5.8 贝叶斯更新

贝叶斯更新强调：判断随新证据变化。开放式调研的结论不应写成永久判断，而应写成条件性判断。

$$P(H | E) \propto P(H) \times P(E | H)$$

在报告中，这可以转化为三类内容：

1. 当前判断：基于现有证据，哪个解释最有力？

2. 更新规则：哪些新证据会提高或降低置信度？
3. 停止条件：什么时候可以形成最终报告，什么时候必须继续调研？

这也是多轮调研质量门的理论基础：质量分不足，或当前证据仍指向继续调研时，报告不应因为写出了一个漂亮结论就停止。

3.5.9 决策树

决策树把不确定性转化为条件化行动。它不要求 agent 预测唯一未来，而是要求 agent 说明不同状态下该怎么做。

开放式调研最终应从：

我认为 A 更好。

升级为：

若证据 E1 出现，采取行动 A；若证据 E2 出现，采取行动 B；若关键假设 H 被推翻，停止或转向；若仍缺失决策级证据，进入下一轮调研。

决策树能显著降低谄媚风险，因为它迫使 agent 把结论写成可检验、可更新、可执行的条件系统。

3.6 方法映射总表

数学优化中，为避免局部最优，可以使用：

- Multi-start，多初始点搜索；
- Global optimization，全局搜索；
- Simulated annealing，模拟退火；
- Sensitivity analysis，敏感性分析；
- Robust optimization，鲁棒优化；
- Bayesian updating，贝叶斯更新；
- Adversarial testing，对抗检验；
- Regularization，正则化；
- Scenario analysis，情景分析。

映射到 AI 投资调研中，就是：

数学优化方法	AI 投资调研中的对应方法
重定义目标函数	不问“买不买”，先问“投资目标、期限、仓位和约束是什么”
多初始点搜索	多头、空头、中立、风险经理、长期投资者多视角分析
全局搜索	不只验证单一候选结论，而是比较买入、等待、持有、减仓、替代资产等行动
模拟退火	前期允许保留非常规解释和弱信号，后期再根据证据强度逐步收敛
随机扰动	改变关键假设，如 AI 需求放缓、毛利率下降、出口限制加剧
敏感性分析	测试收入增速、利润率、EPS、PE 倍数变化对股价和行动建议的影响
对抗检验	让 AI 主动反驳自己的多头/空头结论，并指出最薄弱假设
正则化	防止过度拟合热门叙事、近期价格走势和用户原始偏好
贝叶斯更新	随财报、订单、竞争、资本开支数据动态调整判断
鲁棒优化	找到在多种情景下都不太差、可逆性更强、后悔值更低的投资策略
情景分析	不预测唯一未来，而是构造乐观、中性、悲观和压力情景
决策树	不输出单一结论，而是按条件输出行动方案、触发信号和复盘规则

这个映射也可以推广到非投资调研：产品机会对应市场进入和资源配置，技术选型对应架构约束和迁移成本，开源评估对应维护风险和采用边界。核心始终相同：先重构目标函数，再做多路径搜索、反事实压力测试和条件化行动输出。

四、方法：从答案生成到决策优化

下面给出一套通用流程。它可以用于投资研究，也可以用于产品、市场、技术、开源和尽职调查。每个方法都包括三部分：方法说明、英伟达案例和提示词示例。

4.1 重建目标函数

原始问题：

英伟达现在值不值得买？

隐含目标函数很容易变成：

$$\max S_{\text{buy}}$$

这会诱导 agent 寻找“买”或“不买”的理由。更好的目标函数是：

$$\max E[R] - \lambda \mathcal{R} - \gamma \mathcal{U} - \eta \mathcal{O}$$

于是问题被重构为：

在当前价格、估值、市场预期、AI 算力需求、竞争格局和我的投资期限约束下，英伟达的风险调整后预期收益是否有吸引力？如果行动，合理仓位、等待条件和风险控制是什么？

这个重构动作是反谄媚的第一步：agent 不再把用户原句当作目标函数，而是先检查用户真正要优化什么。

英伟达案例中，“是否值得买入”至少可能对应四种不同目标：

目标	更准确的问题
长期复利	未来 5-10 年持有，英伟达能否提供高质量复利？
风险调整收益	当前价格下，上行空间是否补偿回撤风险？
短线交易	未来一个财报周期内，预期差和资金面是否支持交易？
组合配置	在已有科技股敞口下，新增英伟达是否改善组合？

提示词示例：

请先不要回答“买/不买”。请把这个问题重构为一个决策优化问题：

1. 我可能真正要优化的目标有哪些？
2. 每个目标对应的约束条件是什么？
3. 如果缺少投资期限、仓位、风险承受能力，你应如何处理？
4. 请给出一个比“是否值得买入”更严谨的问题表述。

4.2 拆分事实、假设、推断和价值判断

开放式调研中最常见的错误，是把假设说成事实。

类型	英伟达案例示例
事实	英伟达是全球 GPU 和 AI 加速器龙头之一
待验证数据	当前估值、最新收入、毛利率、自由现金流、分析师预期
假设	AI 资本开支未来几年仍保持高增长
推断	英伟达利润会继续高速增长
价值判断	当前估值仍然合理
行动建议	可以买入、等待、持有、减仓或回避

一份可靠报告应让读者清楚看到：哪些是证据，哪些只是待验证假设，哪些是作者的推断。

英伟达案例中，以下句子经常被混用：

句子	更准确分类
英伟达数据中心业务近年来增长显著	历史事实，但仍需最新财报验证
AI 推理会接棒训练成为长期增长动力	假设
CUDA 生态短期难以被替代	推断，需要开发者、客户和迁移成本证据
高估值可以由高增长消化	价值判断，需要隐含预期反推
现在不买以后更贵	情绪化叙事，不是证据

提示词示例：

请把我的问题拆成六层：

1. 已知事实；
2. 需要实时查询的数据；

- 3. 市场共识；
- 4. 尚未验证的关键假设；
- 5. 主观判断或热门叙事；
- 6. 可能改变行动建议的缺失信息。

请不要把假设写成事实。每个核心判断都要说明它属于哪一层。

4.3 区分对象质量与行动吸引力

“好公司”不自动等于“好股票”。更一般地说，“好对象”不自动等于“好行动”。

问题	关注点
英伟达是不是好公司	技术、护城河、商业模式、财务质量、增长空间
英伟达当前是不是好股票	当前价格、隐含预期、上行空间、下行风险、机会成本

这个区分可以推广到其他领域：

- 好产品不等于值得进入的市场；
- 好技术不等于值得采用的技术栈；
- 好开源项目不等于适合当前团队；
- 好公司不等于值得现在投资。

英伟达作为公司，可能具备强技术、强生态、强财务质量和高增长空间。但作为股票，仍必须面对当前估值、市场预期、拥挤交易、利率环境、持仓约束和机会成本。对象质量回答“它好不好”，行动吸引力回答“现在做这件事是否划算”。

提示词示例：

请分开回答两个问题：

1. 英伟达是不是一家优秀公司？请从商业模式、技术壁垒、财务质量和行业空间分析。
2. 英伟达当前是不是一只值得买入的股票？请从当前价格、隐含预期、风险收益比、机会成本和仓位约束分析。

请说明：哪些结论只支持“公司优秀”，哪些结论才能支持“当前行动有吸引力”。

4.4 多初始点搜索

为了避免单一路径收敛，agent 应从多个初始点出发。

在英伟达案例中，至少包括：

1. 多头基金经理：为什么还能上涨？
2. 空头研究员：市场哪里过度乐观？
3. 中立卖方分析师：哪些指标最影响一致预期？
4. 长期价值投资者：自由现金流和安全边际是否足够？
5. 成长股投资者：增长能否持续消化估值？
6. 短线交易者：资金、趋势和财报波动如何？
7. 风险管理者：组合暴露和最大回撤是否可承受？

多视角不是为了平均主义，而是为了暴露每个观点的盲区。

各视角在英伟达案例中的典型关注点如下：

视角	可能看到的机会	可能忽略的风险
多头基金经理	AI 算力需求、CUDA 生态、Blackwell 周期	估值和拥挤交易
空头研究员	capex 放缓、毛利率下行、自研芯片替代	技术领先持续超预期
中立分析师	财报指引、EPS 上修、供应链瓶颈	极端情景
长期价值投资者	护城河和现金流	当前安全边际不足
成长股投资者	TAM 扩张和新增长曲线	增长放缓后的估值压缩
短线交易者	趋势、资金、财报波动	基本面长期变化
风险管理者	仓位、相关性、最大回撤	过度保守导致错过机会

提示词示例：

请分别从以下七个视角分析同一问题：多头基金经理、空头研究员、中立卖方分析师、长期价值投资者、成长股投资者、短线交易者、风险管理者。

每个视角都要说明：

1. 核心判断；
2. 最关键证据；
3. 最担心的变量；
4. 当前行动建议；
5. 这个视角自己最可能犯的错误。

最后请比较：哪些分歧来自事实不同，哪些分歧来自目标函数不同。

4.5 反事实扰动

一个结论只有在关键假设被扰动后仍然站得住，才具备鲁棒性。

英伟达案例中的关键反事实包括：

- 如果 AI 资本开支放缓怎么办？
- 如果大客户自研芯片替代加速怎么办？
- 如果毛利率下降怎么办？
- 如果 Blackwell 需求继续超预期怎么办？
- 如果出口管制或地缘约束加剧怎么办？
- 如果宏观利率上行导致成长股估值压缩怎么办？

每个反事实都要回答三个问题：它会改变哪些证据、改变哪些假设、改变什么行动。

英伟达案例中的五个关键反事实可以进一步展开：

反事实	影响路径	行动含义
AI capex 放缓	数据中心收入增速下修，市场重估 TAM	暂停追高，等待订单和指引验证
毛利率下降	利润弹性下降，EPS 预期下修	估值中枢可能下移
自研芯片替代加速	客户集中风险放大，议价能力下降	降低长期垄断假设
Blackwell 需求超预期	EPS 上修，供需紧张延续	可以提高乐观情景权重
出口管制加剧	部分市场受限，产品结构变化	需要重估区域收入和利润率

提示词示例：

请对当前结论做反事实压力测试。至少讨论：

1. AI 资本开支放缓；
2. 毛利率下降；
3. 云厂商自研芯片替代加速；
4. 新产品周期超预期；
5. 出口管制或监管约束加剧；
6. 宏观利率上行导致成长股估值压缩。

每个反事实都要说明：对收入、利润率、估值倍数、股价空间和行动建议的影响。

4.6 敏感性分析

敏感性分析要找出真正决定成败的变量。没有敏感性分析报告，往往会把所有因素平铺罗列，读者看不出什么最重要。

英伟达案例中，关键变量至少包括：

1. 数据中心收入增速；
2. 毛利率；
3. 经营费用率；
4. EPS 增速；
5. Forward PE；
6. AI 资本开支持续性；
7. 大客户集中度；
8. 竞争替代速度；
9. 市场风险偏好；
10. 利率水平。

一个简化框架是：

$$P_{\text{future}} = \text{EPS}_{\text{fwd}} \times \text{PE}_{\text{fwd}}$$

于是可以得到三类典型情形：

情形	EPS	PE	可能结果
乐观	上修	维持或小幅扩张	股价继续上涨
中性	小幅上修	小幅压缩	收益有限，波动较大
悲观	下修	压缩	EPS 与估值双杀

提示词示例：

请做敏感性分析，找出最能改变结论的变量。请至少分析：收入增速、毛利率、EPS 增速、Forward PE、AI capex、竞争替代、出口管制和宏观利率。

请给出乐观、中性、悲观三种情景，并说明在哪些变量变化后，行动建议会从买入变为观察，或从观察变为回避。

4.7 估值隐含预期反推

估值不是一个静态标签。高估值本身不必然意味着高风险，低估值也不必然意味着便宜。关键是当前价格隐含了怎样的未来。

简化表达：

$$P = \text{EPS}_{\text{fwd}} \times \text{PE}_{\text{fwd}}$$

如果投资者希望获得合理回报，就需要反推：

- 未来 EPS 需要增长到什么水平；
- 退出时 PE 需要维持在什么水平；
- 增长兑现需要多久；
- 如果 PE 压缩，EPS 增长能否抵消；
- 如果 EPS 下修和 PE 压缩同时发生，下行空间多大。

这个步骤能阻止 agent 用“公司很好”替代“价格合理”。

英伟达案例中，不应只说“PE 高”或“PE 不高”，而要反推：

- 若要求未来 3 年年化 10% 回报，收入和 EPS 需要达到什么水平？
- 若退出 PE 压缩，EPS 增长需要多快才能抵消？
- 若市场已经预期高增长，什么程度的超预期才会带来上行？
- 当前估值是否隐含毛利率长期维持高位？

提示词示例：

请不要只评价估值高低。请反推当前价格隐含的未来预期：

1. 当前价格对应未来 3 年、5 年 EPS 需要达到什么水平？
2. 如果投资者要求年化 10%、15%、20% 回报，对应需要怎样的 EPS CAGR 和退出 PE？
3. 如果 PE 压缩到不同水平，股价空间如何变化？
4. 当前市场预期是否已经过于乐观？

4.8 对抗性验证

报告应同时生成最强正方和最强反方，而不是只列几个象征性风险。

对抗流程可以是：

1. 写出最强买入逻辑。
2. 写出最强不买逻辑。
3. 指出双方最脆弱的假设。
4. 判断哪些证据更强、哪些证据仍缺失。
5. 给出条件化行动，而不是单一路径结论。

对抗性验证的目的不是制造中庸结论，而是让结论经得起攻击。

英伟达案例中，最强买入逻辑可能是：AI 算力需求仍在扩张、公司技术领先、软件生态强化硬件粘性、数据中心业务仍可能超预期、现金流和利润率质量高。最强不买逻辑可能是：当前估值隐含极高增长、客户资本开支可能周期波动、竞争和自研芯片会侵蚀部分市场、出口限制存在、只要业绩符合预期而非超预期，股价也可能回调。

提示词示例：

请做三段式对抗验证：

1. 写出最强买入论证；
2. 写出最强不买论证；
3. 以投资委员会主席口吻指出双方最薄弱假设，并给出经过对抗检验后的条件化结论。

要求：不要中庸化处理，要明确说明当前最需要验证的关键证据。

4.9 贝叶斯更新

调研结论应以“当前证据下”的形式存在，并附带更新规则。

假设	当前证据	提高置信度的证据	降低置信度的证据
AI capex 持续增长	云厂商资本开支和订单信号	指引上修、订单能见度提高	capex 放缓、库存上升
毛利率维持高位	产品结构和供需格局	新产品放量且价格稳定	竞争加剧、客户议价增强
估值可被增长消化	EPS 上修预期	EPS 上修快于股价上涨	EPS 下修或 PE 压缩

这一步把报告从“结论文档”变成“可更新的判断系统”。

提示词示例：

请把当前判断写成可更新的假设系统：

1. 主要投资假设是什么？
2. 每个假设当前证据强度如何？
3. 后续需要跟踪哪些数据？
4. 哪些证据会提高买入概率？
5. 哪些证据会降低买入概率？
6. 哪些证据会彻底推翻投资逻辑？

4.10 情景分析与决策树输出

最终报告应把研究转化为行动边界：

若估值合理且盈利预期继续上修：可以考虑小仓位或分批配置。

若股价上涨快于盈利预期上修：观察，不追高。

若 AI 资本开支放缓：暂停买入，重新评估。

若毛利率或数据中心增速明显恶化：降低仓位或回避。

若已有较高科技股敞口：控制仓位，优先管理相关性风险。

决策树比单句结论更适合真实世界，因为真实世界会变化。

情景分析不是简单写“乐观、中性、悲观”，而是要让每个情景对应可行动策略。

情景	基本假设	操作含义
乐观	EPS 持续上修，PE 不明显压缩，AI capex 稳定	可考虑小仓位或分批配置
中性	增长仍好但预期差有限，估值小幅压缩	等待更好价格或新证据
悲观	capex 放缓、毛利率下降、PE 压缩	回避、减仓或重新评估

提示词示例：

请不要给单一买/不买结论。请输出决策树：

1. 什么情况下可以买入？
2. 什么情况下应该等待？
3. 什么情况下应该回避？
4. 如果已经持有，如何处理？
5. 如果还没买，等待什么信号？
6. 合理仓位如何设置？
7. 复盘和止损条件是什么？

4.11 加入个人约束条件

没有用户约束的建议，往往没有意义。同一个标的，对不同投资者可能对应完全不同的行动。

投资者类型	可能结论
长期成长投资者	可以接受波动，但要验证长期增长和估值消化
价值投资者	可能要求更高安全边际
短线交易者	更关注财报窗口、趋势和资金行为
保守投资者	可能不适合高波动高估值资产
已有大量 AI 仓位的人	新增仓位的组合价值较低
没有科技股仓位的人	小仓位配置可能有分散意义

提示词示例：

请根据不同约束分别给出行动建议：

- 1. 长期成长投资者；
- 2. 价值投资者；
- 3. 短线交易者；
- 4. 保守型投资者；
- 5. 激进型投资者；
- 6. 已有大量 AI/半导体仓位的人；
- 7. 完全没有科技股仓位的人。

每类都要说明：是否适合行动、合理仓位、主要风险、需要等待的信号、判断错了以后如何处理。

4.12 正则化：防止过度拟合热门叙事

热门叙事会让 agent 输出流畅但脆弱的答案。正则化的作用是主动加入会约束叙事的变量。

在英伟达案例中，正则化不是否认 AI 产业趋势，而是要求报告同时处理：

- 1. 估值是否已经反映乐观预期；
- 2. 近期股价上涨是否导致预期透支；
- 3. AI 趋势是否能转化为客户 ROI；
- 4. 大客户是否会降低对单一供应商依赖；
- 5. 毛利率是否能长期维持；
- 6. 宏观利率和风险偏好是否支持高估值。

提示词示例：

请为当前分析加入反叙事正则项：

- 1. 不把伟大公司自动推导为当前值得买；
- 2. 不把近期上涨外推为未来上涨；
- 3. 不用 AI 大趋势替代估值和预期差分析；
- 4. 主动列出最强空头证据；
- 5. 在缺少实时数据时降低结论确定性；
- 6. 明确仓位、期限和风险承受能力如何改变建议。

五、最小评估框架

为了让本文不只是方法主张，需要给出可检查的评估标准。下面是一个轻量评估方案，适合用于 agent 输出质量检查。

5.1 基线与改进提示

基线提示：

深度调研英伟达这支股票现阶段值不值得买入？

改进提示：

请先重构该问题的目标函数、约束条件和关键假设，再基于证据、反方论证、估值隐含预期、情景分析和更新规则，给出条件化行动建议。

5.2 评估维度

维度	低质量输出	高质量输出
目标函数	直接回答买/不买	先定义收益、风险、期限、仓位和机会成本
事实边界	把叙事当事实	区分事实、假设、推断和价值判断
证据质量	引用笼统材料	明确来源、时间、数据口径和冲突证据
反方强度	风险一笔带过	给出能真正推翻结论的反方逻辑
敏感性	只有单一情景	说明关键变量如何改变结论
决策价值	像材料汇编	给出行动边界、触发条件和复盘规则
可更新性	一次性定论	说明哪些新证据会改变判断

5.3 通过门限

一份报告达到通过标准，不是因为它看起来全面，而是因为它能回答：

1. 读者要优化什么？
2. 结论依赖哪些假设？
3. 哪些证据最强，哪些证据最弱？
4. 哪些变量最可能改变行动建议？
5. 当前行动为什么优于替代行动？
6. 如果判断错了，如何发现并更新？

如果这些问题回答不清楚，报告应继续下一轮调研，而不是提前写最终结论。

六、局限性

本文方法不是万能的。

第一，它不能消除不确定性。约束优化和贝叶斯更新只能改善判断结构，不能保证预测正确。

第二，它依赖证据质量。如果来源过时、数据口径错误或关键数据缺失，再好的框架也可能给出误导性判断。

第三，它可能增加调研成本。对简单事实问题，完整流程会显得过重；它更适合高不确定性、高代价、开放式的决策问题。

第四，它不能替代专业责任。投资、医疗、法律等高风险领域仍需要专业判断和责任边界。AI 可以组织证据和推理，但不应伪装成最终责任主体。

第五，它仍可能被形式主义侵蚀。如果 agent 只是机械填表，把每个环节变成审计清单，报告仍然会失去可读性。真正的目标是服务人类决策者，而不是证明 agent 做过很多步骤。

七、附录：可复用提示模板

下面的模板不是唯一正确写法，而是一种把开放式问题重构为决策优化问题的起点。

我想深度调研一个开放式问题：[填写问题]

请把这个任务当作开放式决策调研，而不是直接回答题面问题。你的目标是帮助人类决策者形成可复核、可更新、可行动的判断。

请按以下流程输出：

一、目标函数

1. 用户真正要优化的是什么？
2. 这个目标是否和原始问法一致？
3. 如果原始问法有误导性，应如何重写？
4. 最终需要支持什么行动：选择、排序、进入、退出、买入、等待、采用、放弃，还是继续调研？

二、约束条件

1. 时间期限是什么？
2. 风险承受边界是什么？
3. 资源、预算、仓位、组织能力或机会成本是什么？
4. 哪些约束缺失但会改变结论？
5. 如果约束缺失，请给出不同约束下的分条件判断，而不是假装约束不存在。

三、研究框架

1. 这个问题适合用什么研究框架？
2. 该框架包含哪些核心维度？
3. 每个维度为什么会影响最终行动？
4. 哪些维度只是背景信息，哪些维度会真正改变决策？

如果是证券或公司尽调，可以考虑：

- 市场环境；
- 行业主题；
- 公司业务结构；
- 财务质量；
- 估值和隐含预期；
- 机构预期；
- 资金面和技术面；
- 催化剂；
- 风险和反证。

如果是产品或市场调研，可以考虑：

- 用户需求；
- 现有替代方案；
- 竞品格局；
- 分发渠道；
- 付费意愿；
- 单位经济模型；
- 进入壁垒；
- 监管和平台约束；
- 执行难度。

四、事实、假设和推断

1. 已知事实是什么？
2. 需要实时查询的数据是什么？
3. 尚未验证的关键假设是什么？

4. 哪些是主观判断或市场叙事?
5. 哪些结论只是推断, 不应写成事实?
6. 哪些事实如果被证伪, 会改变最终行动?

五、证据计划

1. 需要哪些一手来源、官方来源或权威数据?
2. 哪些来源只能作为辅助信号?
3. 每个关键 claim 需要什么 evidence 支撑?
4. 对来源的新鲜度、利益冲突和口径差异如何处理?
5. 如果证据冲突, 请解释冲突来源, 而不是简单平均。

六、多视角分析 请至少从支持者、反对者、中立分析者、风险管理者和最终决策者视角分析。每个视角说明:

1. 核心逻辑;
2. 关键证据;
3. 最担心的变量;
4. 可能犯的错误;
5. 对行动建议的影响。

七、反事实与敏感性

1. 哪些关键变量最影响结论?
2. 如果这些变量反向变化, 结论是否改变?
3. 哪些证据会推翻当前判断?
4. 请给出乐观、中性、悲观和压力情景。
5. 请说明每个情景下的行动含义。

八、隐含预期反推

1. 当前行动隐含了什么未来预期?
2. 这些预期需要哪些事实成立?
3. 要达到目标收益、目标增长或目标结果, 关键变量需要达到什么水平?
4. 如果关键变量不达标, 损失或机会成本是什么?

九、对抗性验证

1. 写出最强支持论证;
2. 写出最强反对论证;
3. 指出双方最薄弱的假设;
4. 说明目前哪一方证据更强;
5. 明确还缺哪些会改变结论的证据。

十、贝叶斯更新

1. 当前最可能的解释是什么?
2. 当前置信度大致处于高、中、低哪个级别?
3. 哪些新证据会提高置信度?
4. 哪些新证据会降低置信度?
5. 哪些证据会触发收窄问题、转向假设、放弃路径或继续调研?

十一、综合判断与决策树 请给出条件化结论、决策树、下一步观察指标和复盘规则:

1. 当前最合理行动是什么?
2. 哪些条件成立时可以更积极?
3. 哪些条件成立时应该等待、缩小范围或放弃?
4. 如果判断错了, 如何发现?
5. 下一轮最值得调研的问题是什么?

十二、最终报告要求 正文应写成给人类决策者阅读的报告，先讲判断逻辑，再放证据细节。证据登记、审计表、来源清单和过程说明可以进入附录或过程文件。结论应服务人类决策者，而不是成为任务过程审计。

八、结论

开放式调研最危险的失败模式，不是 agent 没有找到足够多材料，而是它太快接受了用户问题里的初始方向。它看似在帮助用户，实际上可能只是把用户的初始偏见扩写成一份结构完整的报告。

用约束优化方法重构开放式调研，核心不是增加术语，而是改变任务本质：

从：回答用户问了什么 到：识别用户真正需要优化什么

从：证明一个候选结论 到：比较多个可行动方案

从：一次性输出观点 到：建立可更新的判断系统

对英伟达这类强叙事、高共识、高估值标的，AI 分析的核心不是证明它好，而是检验“当前价格是否已经把它的价值充分定价”。对任何开放式调研任务，AI 的核心责任也不是迎合用户的初始表述，而是帮助人类决策者在不确定性中形成更清醒、更可复核、更能更新的判断。

九、参考文献与延伸阅读

1. Sharma, M. et al. “Towards Understanding Sycophancy in Language Models.” arXiv:2310.13548.
2. Wei, J. et al. “Simple synthetic data reduces sycophancy in large language models.” arXiv:2308.03958.
3. Perez, E. et al. “Discovering Language Model Behaviors with Model-Written Evaluations.” arXiv:2212.09251.
4. Ouyang, L. et al. “Training language models to follow instructions with human feedback.” arXiv:2203.02155.
5. Bai, Y. et al. “Constitutional AI: Harmlessness from AI Feedback.” arXiv:2212.08073.
6. Ben-Tal, A., El Ghaoui, L., and Nemirovski, A. Robust Optimization. Princeton University Press, 2009.
7. Gorissen, B. L., Yanikoglu, I., and den Hertog, D. “A Practical Guide to Robust Optimization.” arXiv:1501.02634.
8. Tetlock, P. E., and Gardner, D. Superforecasting: The Art and Science of Prediction. Crown, 2015.
9. Howard, R. A., and Abbas, A. E. Foundations of Decision Analysis. Pearson, 2015.